Web Scraping con Pentaho Data Integration

Transformando código HTML no estructurado en inteligencia de negocios.

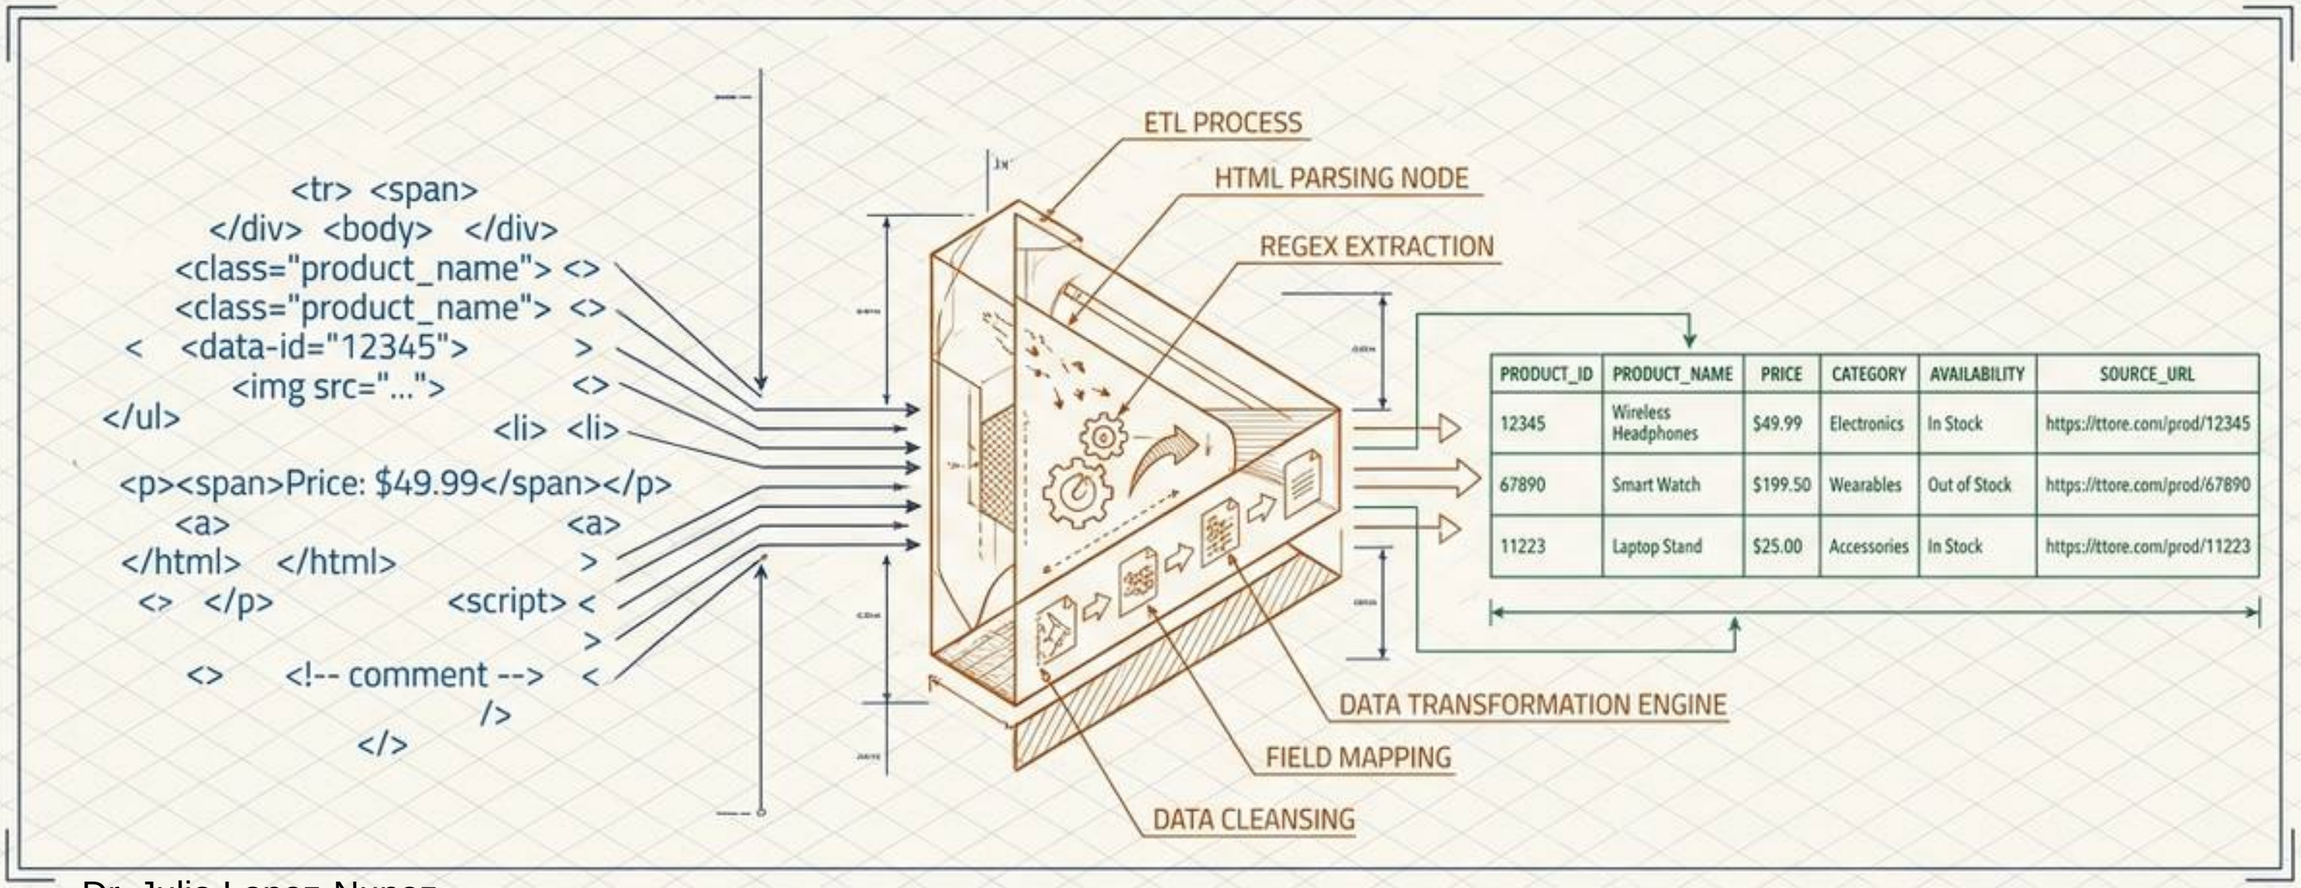

PRODUCT_ID	PRODUCT_NAME	PRICE	CATEGORY	AVAILABILITY	SOURCE_URL
12345	Wireless Headphones	$49.99	Electronics	In Stock	https://ttore.com/prod/12345
67890	Smart Watch	$199.50	Wearables	Out of Stock	https://ttore.com/prod/67890
11223	Laptop Stand	$25.00	Accessories	In Stock	https://ttore.com/prod/11223

Dr. Julio Lopez-Nunez
2026

NotebookLM

Los datos no siempre vienen en bandeja de plata

El Ideal

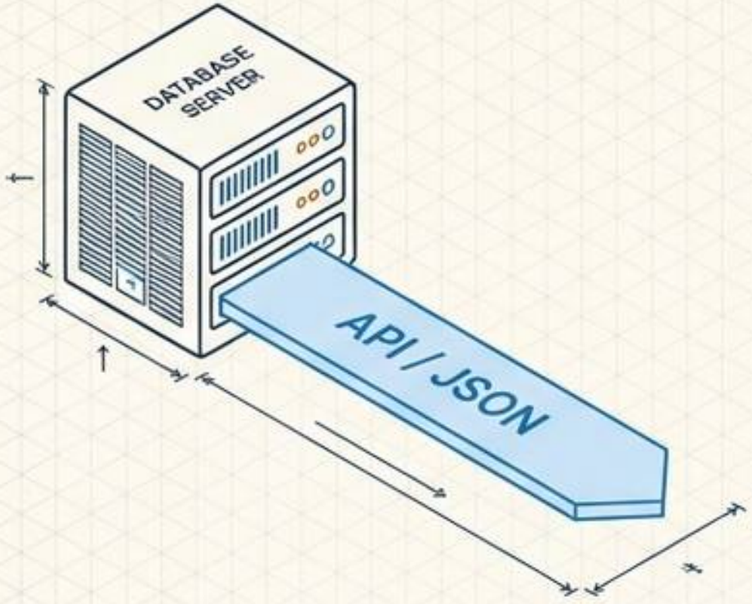

Sistemas diseñados para compartir información directamente con máquinas.

La Realidad del Scraping

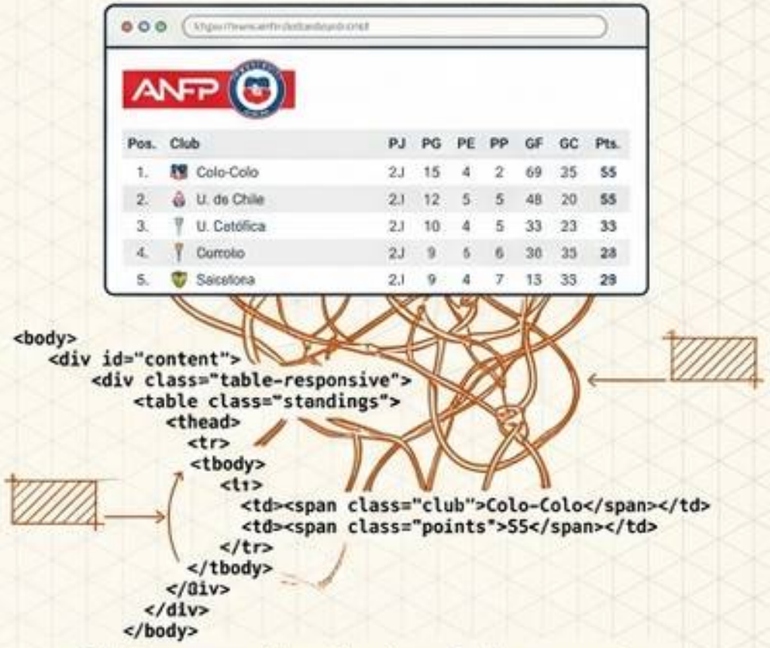

Sistemas diseñados únicamente para la visualización humana.

El web scraping es el arte de forzar la extracción de datos, reconstruyendo la estructura oculta dentro de una interfaz gráfica para transformarla en un insumo analítico.

NotebookLM

Web Services vs. Web Scraping: Una decisión estratégica

	Web Services (Contrato Formal)	Web Scraping (Ingeniería Inversa)
Propósito Original	Diseñado para consumo automatizado de máquinas.	Diseñado exclusivamente para lectura humana.
Formato de Origen	Datos estructurados y limpios (JSON, XML). `{"key": "value"}` ... ... `<data>clean</data>`	Código crudo, diseño y formato visual (HTML masivo). `<div> <div><span>.. <tr> <span>... <//span> </div> </dlv>`
Esfuerzo ETL	Bajo. Mapeo directo de campos predefinidos. Source → Target	Alto. Uso intensivo de Regex, Parsing y limpieza. `/^data:\s*(.*)$/ parsing (*) /"data:\s*(.*)$/ parsing:[*,*]/ ...`
Fiabilidad	Alta y estable a lo largo del tiempo.	Frágil. Se rompe inmediatamente si cambia el diseño de la web.

Conclusión: El scraping es una alternativa poderosa para democratizar datos, pero introduce una dependencia estructural externa que exige mantenimiento constante.

NotebookLM

El paradigma ETL aplicado a datos no estructurados

E : Extracción

Captura del Océano

Descarga del código HTML completo como un único bloque masivo de texto.

T : Transformación

La Refinería

Parsing Normalización Limpieza Regex

Enseñar a la máquina a encontrar piezas lógicas, rotarlas y eliminar el ruido visual.

L : Carga

El Producto Final

Generación de un archivo tabular limpio y estructurado (.txt).

[ESTADO DEL DATO: 0% ESTRUCTURADO]

[ESTADO DEL DATO: 100% ESTRUCTURADO]

NotebookLM

Fase 1: Ignición y captura del código fuente

The PDI Flow

Funciona como la llave de inicio. Genera exactamente 1 registro para disparar el flujo.

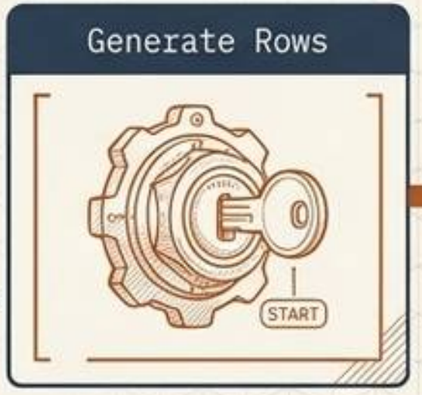

Se conecta a la URL y descarga el sitio web completo.

The Data State Tracker

[ESTADO DEL DATO: FASE 1]

variable	
	<!DOCTYPE html><html lang="en"><head><meta charset="UTF-8"><title>Sample Website</title><link rel="stylesheet" href="style.css"></head> <body>><header><nav><ul>$li><a href="Nhome"rHome<+/a></l1><li><a href="$about"#>Aboutc/a></li></ul></hav></header><main><<section id="hero"> <<section id="horo"><hi>Welcome to Our Site</p>This is raw HTML content downloaded from the web.<p></section> <section class="data-container"><div><span class="price">$?$19.99Nidget A $19.99 $29.99</span><span class="product">Widget B</span></div> <span class="prtce$">$24.36>$04/span>$22:8ecCnnoapwtoc</sserainss":m/triges"></section> <footer><<a>coaens; 26+</cos><srfooter><script src="script.js"><xdiv></apan><scrlpt<sz"=erscript"><sssxzvix="2x3+23">></script></scipt> <script src="script.js"></script><overasst"contesns">oracoptasx-ammercing">5heme+&aome</agt></home><link rel=>atabotsl>#1est>span class="prics">$ADgt9risoax><script src="script.js"></script></dav><ssnt.orsny" href="ouesereIIJeetora7> <script src="script.js"><s/flzot></wectsisnsrerseemnr"ava9$eria/i></cript><fitle/ecss"hrc="a/xdsnsplr=Company samvems/ip> <script src="script.js"></script><contaatc"cmroy/ex/pnszntsd scc="script>8homez/homes/div><span class>"script"+S&et8a><s=fore <anav="pro-btscn-conotanes/set/on=container->xswex="mlagnet"><span class="neorox"stm&avaror"></di><span="product">Widgetkxs <script src="script.js"></script></da></script><script src="script.js"></script><dataloacks="stylemsescspf"><footer> © 2024 Companyrnnyxiame </footer><script src="script.js"></script></body></html>

Todo el sitio web existe temporalmente comprimido como una sola celda masiva de texto.

NotebookLM

Fase 2A: Fragmentación estructural mediante Parsing

The PDI Flow

Al reemplazar el delimitador por defecto (coma) por el tag HTML <tr>, la máquina aprende a separar la página web en pedazos lógicos.

The Data State Tracker

[ESTADO DEL DATO: FASE 2A]

variable					
Fila 0	Fila 1	Fila 2	Fila 3	...	...
<td>Product A</td> <td>$10</td>	<td>Product B</td> <td>$20</td>	<td>Product C</td> <td>$30</td>	<td>Product D</td> <td>$40</td>	<td>Product E... ...	<td>Product E... ...

NotebookLM

Fase 2B: El pivote que crea la estructura tabular

The PDI Flow

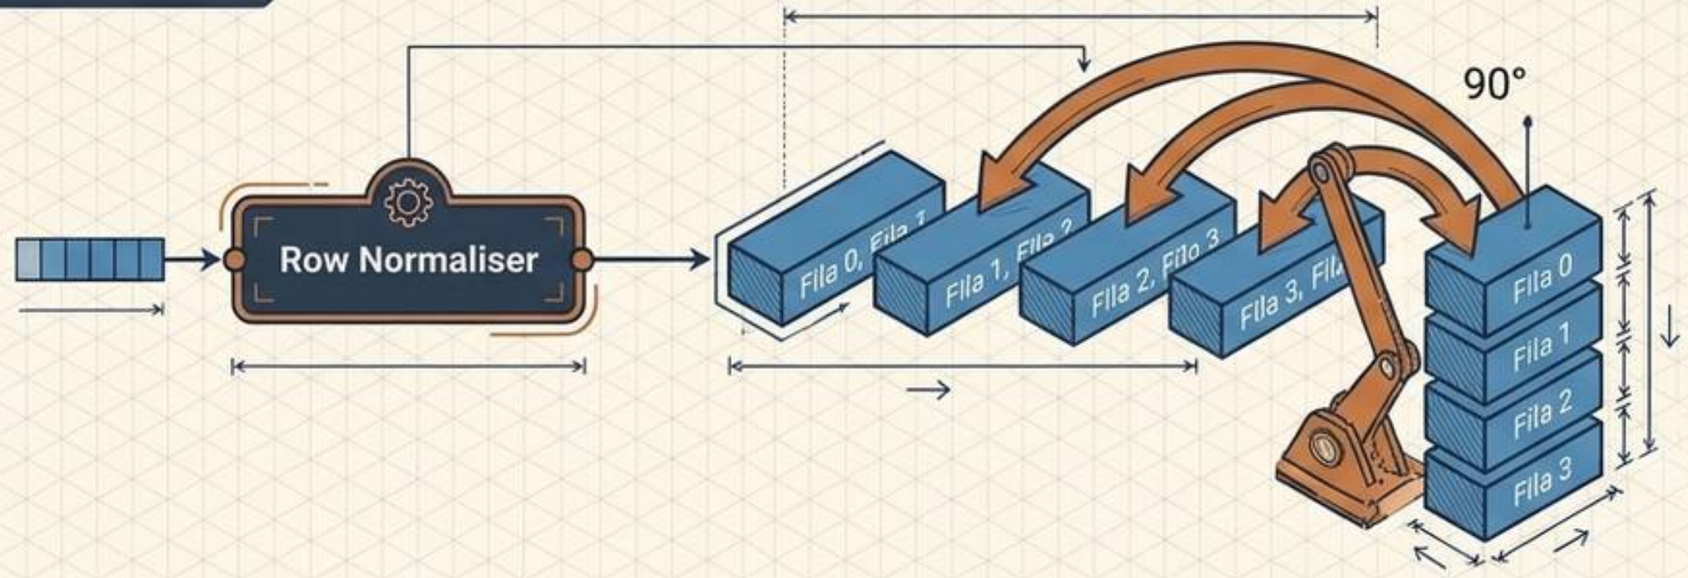

Este componente transforma los campos expandidos horizontalmente en un solo atributo común nombrado “filas”. Es el paso clave para convertir código crudo en una entidad estructurada de base de datos.

The Data State Tracker

[ESTADO DEL DATO: FASE 2B]

	filas
0	<td>Product A</td><td>$10</td>
1	<td>Product B</td><td>$20</td>
2	<td>Product C</td><td>$30</td>
3	<td>Product D</td><td>$40</td>
	...

NotebookLM

Fase 3A: Descarte de ruido estructural

The PDI Flow

Fila 0
Fila 1
Fila 2
Fila 3
Fila 4
...

Si Time_Field = Fila 0
(Cabecera web)

Descartar

Si Time_Field = Fila 1
(Encabezados de tabla)

Descartar

Fila 2
Fila 3
Fila 4
...

The Data State Tracker

[ESTADO DEL DATO: FASE 3A]

Fila 0	~~<tr>...Cabecera web...</tr>~~
Fila 1	~~<tr>...Encabezados de tabla...</tr>~~
Fila 2	<tr><td>Club A</td><td>Stats..</td></tr>
Fila 3	<tr><td>Club B</td><td>Stats..</td></tr>
...	...

NotebookLM

Fase 3B: Extracción quirúrgica con Regex

Code Anatomy (Node: JavaScript)

Measurade 2D line

Engineering Blue → (>)(.*?)(<) ← Engineering Blue

Unión La Calera

Carne del dato

ubicacion

equipo

Dew Catàas columns

[ESTADO DEL DATO: FASE 3B]

	original column	new column	equipo column
1	Unión La Calera	1	Unión La Calera

NotebookLM

Fase 3C: Lavado final de etiquetas HTML

The PDI Flow

Unión La Calera

1</a>

 | </a>

Unión La Calera

1

El operador **Pipe** (| como operador lógico OR) permite buscar y destruir múltiples etiquetas basura simultáneamente.

Reemplazar por:
[ESPACIO VACÍO]

The Data State Tracker

[ESTADO DEL DATO: FASE 3C]

ID	Nombre del Club	Goles
1	Unión La Calera	18

NotebookLM

Fase 4: Exportación del producto final

The PDI Flow

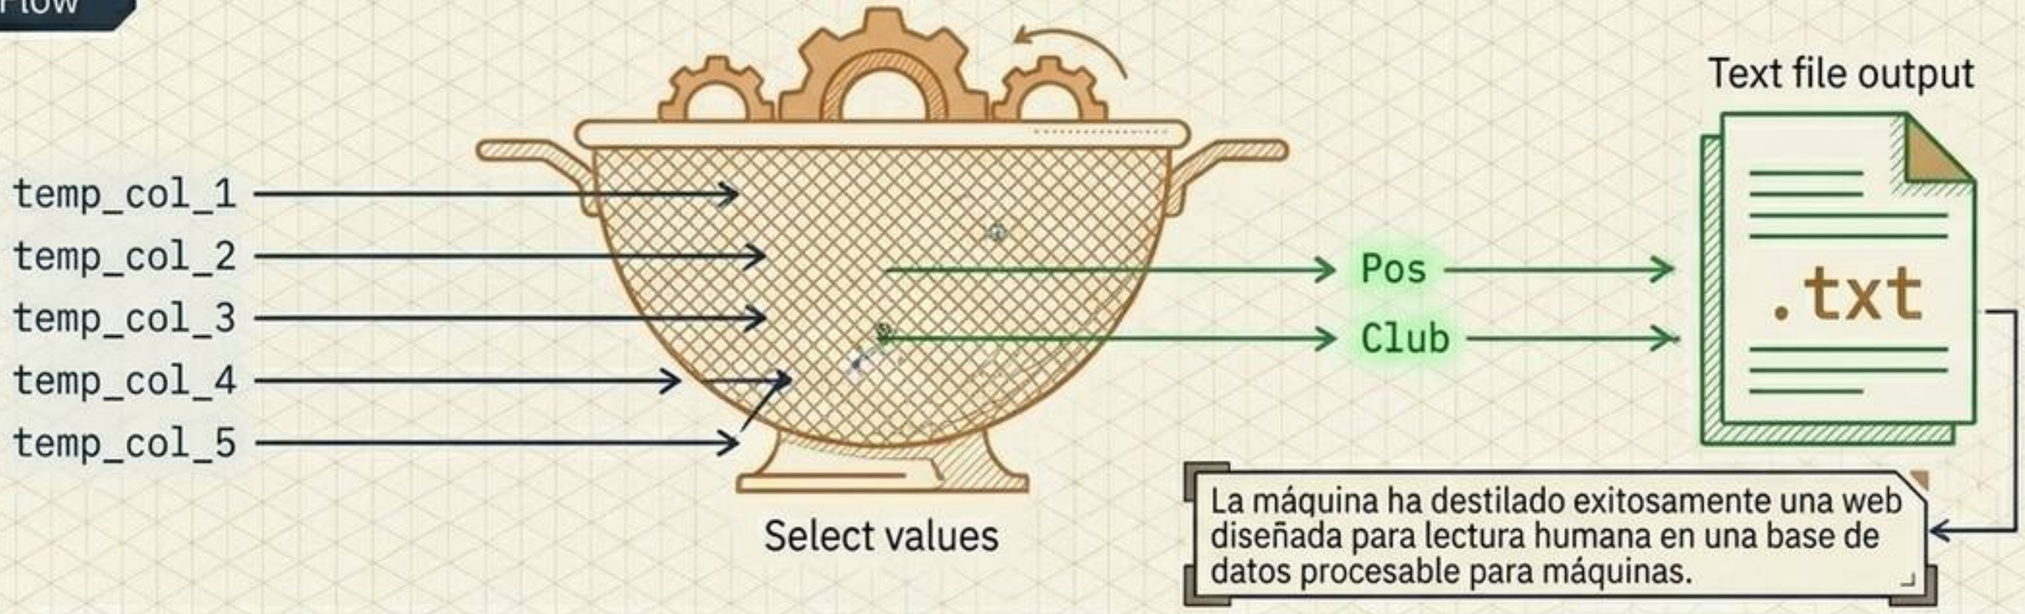

The Data State Tracker Producto Final

[ESTADO DEL DATO: PRODUCTO FINAL]

Pos	Club
1	Unión La Calera
2	Cobresal
3	Ñublense
4	Curicó Unido
5	Everton
6	Colo-Colo

NotebookLM

La Arquitectura Completa de la Refinería

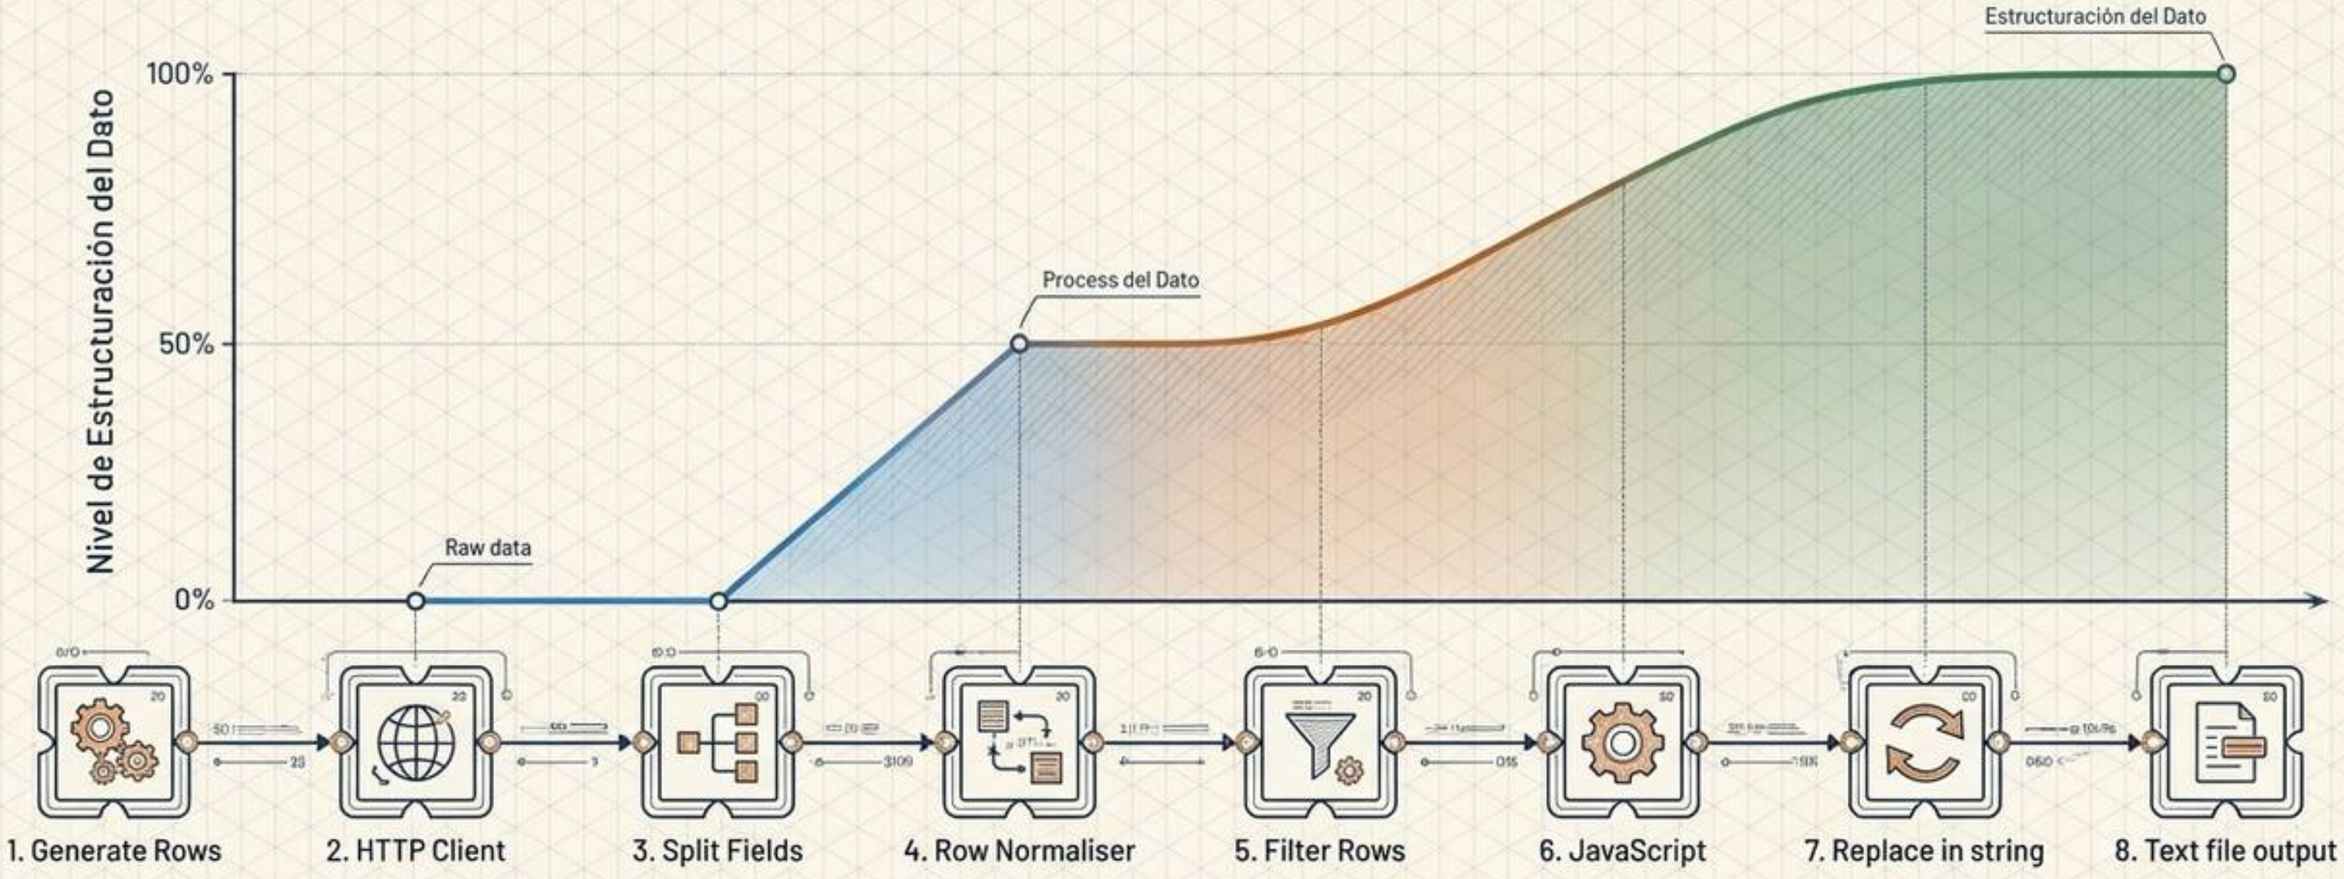

El Web Scraping no es un acto instantáneo de captura. Es un ensamblaje artesanal de ingeniería, necesario para enseñar a un sistema a leer la estructura implícita en el caos visual y guardar los resultados como una máquina.

NotebookLM